

# Exercícios de Reconhecimento de Padrões

19 de março de 2024

## 1 KNN

### 1.1 Exercício de Fixação 1

- **Objetivos:** familiarização com o KNN [CH67] e implementação inicial.
- **Tarefa:** dar continuidade à implementação do KNN iniciada em sala de aula e familiarizar com o método observando o desempenho do método em função do parâmetro  $k$ . Código com a implementação é apresentado a seguir; o aluno deve utilizá-lo como referência realizando a sua própria implementação.

```
> rm(list = ls())
> myknn<-function(xt,xall,yall,k)
+ {
+   Nall<-dim(xall)[1]
+   repxt<-matrix(xt,nrow = Nall,ncol = 2,byrow = T)
+   dall<-data.matrix(rowSums((xall-repxt)^2))
+   orddall<-order(dall)
+
+   yhat<-sign(sum(yall[orddall[1:k]]))
+   return(yhat)
+ }
> k<-5
> N<-30
> xc1<-matrix(rnorm(2*N,mean = 2, sd=1),ncol=2,nrow = N)
> xc2<-matrix(rnorm(2*N,mean = 4, sd=1),ncol=2,nrow = N)
> xall<-rbind(xc1,xc2)
> yall<-rbind(matrix(-1,ncol = 1,nrow = N),
+             matrix(1,ncol = 1,nrow = N))
> plot(xc1[,1],xc1[,2],xlim=c(0,6),
+      ylim = c(0,6),col='red')
> par(new=T)
> plot(xc2[,1],xc2[,2],xlim=c(0,6),
```

```

+       ylim = c(0,6),col='blue')
> xt<-matrix(c(3,2),ncol = 1,nrow = 2)
> myknn(xt,xall,yall,k)

[1] -1

> seqx1x2<-seq(0,6,0.1)
> lseq<-length(seqx1x2)
> MZ<-matrix(nrow=lseq,ncol=lseq)
> cr<-0
> for (i in 1:lseq)
+ {
+   for (j in 1:lseq)
+   {
+     cr<-cr+1
+     x1<-seqx1x2[i]
+     x2<-seqx1x2[j]
+     retknn<-myknn(as.matrix(c(x1,x2)),xall,yall,20)
+     MZ[i,j]<-retknn
+   }
+ }
> image(MZ)
> persp(seqx1x2,seqx1x2,MZ,xlim=c(-2,10),
+       ylim=c(-2,10),xlab="x1",
+       ylab="x2",theta = 60, phi = 40)
> contour(seqx1x2,seqx1x2,MZ,nlevels=1,xlim=c(0,6),
+       ylim = c(0,6),xlab="x1",ylab="x2")
> par(new=T)
> plot(xc1[,1],xc1[,2],xlim=c(0,6),
+       ylim = c(0,6),col='red')
> par(new=T)
> plot(xc2[,1],xc2[,2],xlim=c(0,6),
+       ylim = c(0,6),col='blue')

```

- **Apresentar:** Gráficos diversos com diferentes respostas do modelo para valores diferentes de  $k$ . Apresentar em um parágrafo de no máximo 10 linhas uma discussão dos resultados.

## 1.2 Exercício de Fixação 2

- **Objetivos:** Representação do KNN com ponderação de distâncias e entendimento desta abordagem como uma combinação de funções radiais.
- **Tarefa:** estender a implementação anterior incluindo a ponderação de distâncias para a tomada de decisão da classificação. De acordo com esta abordagem a resposta do KNN é representada na forma

$$\hat{y} = \text{signal}(\sum_{i=1}^N \alpha_i y_i K(\mathbf{x}, \mathbf{x}_i))$$

em que  $\alpha_i = 1 \forall \mathbf{x}_i \in V_k$ ,  $\alpha_i = 0 \forall \mathbf{x}_i \notin V_k$ ,  $V_k$  é o conjunto dos vizinhos mais próximos e  $K(\mathbf{x}, \mathbf{x}_i)$  é um função de kernel radial na forma de uma função Gaussiana.

Avaliar os efeitos dos parâmetros do modelo e da função no desempenho do modelo, considerando a resposta observada da superfície de separação. Para o exemplo de dados sintéticos implementado, a função Gaussiana (Normal) é de duas variáveis, no entanto, sugere-se que ela seja implementada em sua forma geral:

$$p(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^n |\Sigma|}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})\right) \quad (1)$$

em que  $n$  é a dimensão de  $\mathbf{x}$ ,  $\Sigma$  é a matriz de covariâncias,  $|\Sigma|$  o seu determinante e  $\boldsymbol{\mu}$  é o vetor de médias das distribuições marginais, conforme apresentado a seguir nas Equações 2 e 3.

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \rho_{12}\sigma_1\sigma_2 & \cdots & \rho_{1n}\sigma_1\sigma_n \\ \rho_{21}\sigma_2\sigma_1 & \sigma_2^2 & \cdots & \rho_{2n}\sigma_2\sigma_n \\ \vdots & \vdots & \cdots & \vdots \\ \rho_{n1}\sigma_n\sigma_1 & \rho_{n2}\sigma_n\sigma_2 & \cdots & \sigma_n^2 \end{bmatrix} \quad (2)$$

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_n \end{bmatrix} \quad (3)$$

Para facilitar a implementação, considere a seguinte implementação em R da função de densidade Normal multivariada:

```
> pdfnvar<-function(x,m,K,n) ((1/(sqrt((2*pi)^n*(det(K))))) *
+                               exp(-0.5*(t(x-m) %*%
+                               (solve(K)) %*% (x-m))))
```

em que  $\mathbf{K} = h\mathbf{I}$ , sendo assim  $h$  o raio da função Gaussiana.

Nesta etapa o desempenho do classificador será avaliado de acordo com os parâmetros  $k$  e  $h$ .

- **Apresentar:** Gráficos diversos com diferentes respostas do modelo para valores diferentes de  $k$  e  $h$ . Apresentar em um parágrafo de no máximo 10 linhas uma discussão dos resultados.

### 1.3 Exercício Intermediário 1

- **Objetivos:** Avaliar o desempenho do KNN em função do parâmetro  $k$ . Apresentar gráfico de desempenho em função de  $k$ .
- **Tarefa:** Escolha um conjunto de dados real, determine um valor inicial para  $k$ , separe os dados em dois conjuntos, sendo um de referência para o KNN (treinamento) e outro de validação e avalie o percentual de acerto do KNN no conjunto de validação para este valor de  $k$  e partição atual do conjunto de dados. Repita esta operação pelo menos 10 vezes e armazene a média e o desvio padrão do desempenho para este valor de  $k$ . Varie o valor de  $k$  de 1 a um valor mais alto que permita a observação da mudança de comportamento do desempenho do modelo, possivelmente passando por um máximo. Apresente o gráfico obtido de desempenho em função de  $k$  considerando também os desvios.
- **Apresentar:** Apresentar o gráfico solicitado e um parágrafo de no máximo 10 linhas com uma discussão dos resultados. Sugerir uma estratégia para a determinação do valor de  $k$ .

### 1.4 Exercício Intermediário 2

- **Objetivos:** Analisar o comportamento do KNN ponderado como uma função de mapeamento em um espaço de verossimilhanças.
- **Tarefa:** O KNN ponderado pode ser representado na forma de uma função de um somatório de funções de proximidade (funções radiais, funções de kernel), conforme expressão apresentada anteriormente:

$$\hat{y} = \text{signal} \left( \sum_{i=1}^N \alpha_i y_i K(\mathbf{x}, \mathbf{x}_i) \right)$$

em que  $\alpha_i = 1 \ \forall \mathbf{x}_i \in V_k$ ,  $\alpha_i = 0 \ \forall \mathbf{x}_i \notin V_k$ ,  $V_k$  é o conjunto dos vizinhos mais próximos e  $K(\mathbf{x}, \mathbf{x}_i)$  é um função de kernel radial na forma de uma função Gaussiana.

Considerando que  $\alpha_i$  seja o resultado de uma função indicadora dos vizinhos, o somatório será realizado sobre os  $k$  vizinhos, sendo  $k_1$  os vizinhos da classe 1 (positiva) e  $k_2$  os vizinhos da classe 2 (negativa). A expressão anterior pode ser, portanto, reescrita da seguinte forma:

$$\hat{y} = \text{signal} \left( \sum_{i=1}^{k_1} K(\mathbf{x}, \mathbf{x}_i) - \sum_{j=1}^{k_2} K(\mathbf{x}, \mathbf{x}_j) \right)$$

Cada um dos termos do somatório da expressão anterior representa, portanto, uma medida de *pertencimento* entre a amostra  $\mathbf{x}$  que está sendo

avaliada e as demais amostras de cada classe. Estas medidas, que representam similaridades entre  $\mathbf{x}$  e as amostras de cada classe, serão representadas aqui como  $Q_1(\mathbf{x}|C_1)$  e  $Q_2(\mathbf{x}|C_2)$ , podendo a equação original ser novamente escrita em função das mesmas:

$$\hat{y} = \text{sin}(\text{al}(Q_1(\mathbf{x}|C_1) - Q_2(\mathbf{x}|C_2)))$$

Nesta representação a parcela  $Q_i$  de maior magnitude determinará o sinal de resposta do classificador. A expressão característica da reta separadora no plano  $Q_2(\mathbf{x}|C_2) \times Q_1(\mathbf{x}|C_1)$  é  $Q_2(\mathbf{x}|C_2) = Q_1(\mathbf{x}|C_1)$ , ou seja, toda amostra mapeada acima desta reta será classificada como sendo da classe 2 e toda amostra abaixo da reta da classe 1. Toda amostra de entrada, independentemente da dimensão do problema, terá valores correspondentes de  $Q_2(\mathbf{x}|C_2)$  e  $Q_1(\mathbf{x}|C_1)$  e portanto será mapeada no plano  $Q_2(\mathbf{x}|C_2) \times Q_1(\mathbf{x}|C_1)$ .

Neste exercício o aluno deverá observar o comportamento do mapeamento em  $Q_2(\mathbf{x}|C_2) \times Q_1(\mathbf{x}|C_1)$  em função de  $k$  para conjuntos de dados sintéticos, sendo um deles linearmente separável e o outro não-linearmente separável. Pergunta-se: qual o efeito do valor de  $k$  sobre os conjuntos de amostras mapeados? qual o efeito do valor de  $h$  sobre os conjuntos de amostras mapeados? quais as características deste mapeamento quando o valor de  $k$  resulta em desempenho máximo? quais as características deste mapeamento quando o valor de  $h$  resulta em desempenho máximo?

- **Apresentar:** Fazer uma análise dos resultados encontrados visando a identificar características do mapeamento que possam ser utilizadas na seleção do valor de  $k$  e  $h$ . Sugere-se que o aluno leia o trabalho do ex-orientado Murilo Menezes [MTB19] para entender melhor o problema.

## Referências

- [CH67] T. Cover and P. Hart. Nearest neighbor pattern classification. *Information Theory, IEEE Transactions on*, 13(1):21–27, January 1967.
- [MTB19] Murilo VF Menezes, Luiz CB Torres, and Antonio P Braga. Width optimization of rbf kernels for binary classification of support vector machines: A density estimation-based approach. *Pattern Recognition Letters*, 128:1–7, 2019.