

Relatório sobre Análise de Componentes Principais do Conjunto de Dados Olivetti Faces

Eduardo Henrique Basilio de Carvalho

June 2, 2025

1 Introdução

Este relatório resume a aplicação da Análise de Componentes Principais (PCA) no conjunto de dados Olivetti Faces. O objetivo foi realizar a redução de dimensionalidade e avaliar seu impacto em uma tarefa de classificação subsequente.

2 Carregamento de Dados e Exploração Inicial

O conjunto de dados Olivetti Faces foi carregado, consistindo em imagens e rótulos correspondentes. A forma original da matriz de características X era $(400, 4096)$. Estes correspondem a 400 imagens, cada uma representada por um vetor achatado de 4096 valores de pixel (imagens 64x64).

3 Aplicação do PCA e Redução de Dimensionalidade

O PCA foi inicialmente aplicado para reduzir a dimensionalidade do conjunto de dados para 100 componentes.

- Os dados originais X possuíam 4096 dimensões.
- Após aplicar o PCA com $n_{componentes} = 100$, os dados transformados X_{pca} possuíam a forma $(400, 100)$.

Os autovalores, representando a variância explicada por cada componente principal, foram extraídos. Um gráfico de scree (scree plot) foi gerado plotando esses autovalores em ordem decrescente.




Figure 1: Gráfico de scree mostrando os autovalores ordenados. O gráfico demonstra uma queda acentuada na variância explicada pelos componentes após os primeiros, seguida por um declínio mais gradual, uma forma característica de "cotovelo".

A Figura 1 mostra que os primeiros componentes principais capturam uma quantidade significativa de variância, com a variância explicada pelos componentes subsequentes diminuindo rapidamente. Isso é típico no PCA e indica que um número muito menor de componentes pode representar uma grande parte da variabilidade dos dados.

4 Determinando o Número Ótimo de Componentes

Com base na análise visual, o número ótimo de componentes foi determinado como sendo 20. O PCA foi então reaplicado usando $n_{componentes} = 20$.

5 Avaliação do Desempenho da Classificação

Para avaliar a eficácia da redução de dimensionalidade, um classificador Gaussian Naive Bayes foi treinado nos dados transformados pelo PCA (X_{pca} com 20 componentes). O desempenho foi avaliado usando validação cruzada estratificada de 10 folds (10-fold stratified cross-validation). A acurácia reportada da validação cruzada de 10 folds foi 0.93 ± 0.03 . Isso indica que o modelo alcançou uma acurácia média de 93% com um desvio padrão de 3% entre os folds.

6 Conclusão

A aplicação do PCA reduziu significativamente a dimensionalidade do conjunto de dados Olivetti Faces de 4096 características para apenas 20 componentes principais. Apesar desta redução substancial, uma alta acurácia de classificação de 93% foi alcançada usando um classificador Gaussian Naive Bayes. Isso demonstra que o PCA capturou com sucesso as características mais salientes dos dados, permitindo uma classificação eficiente e eficaz em uma representação de dimensionalidade muito menor.