

Exercício PCA

Você trabalha como cientista de dados em uma empresa de tecnologia educacional. A equipe está desenvolvendo um sistema de correção automática de provas escritas com reconhecimento de dígitos manuscritos. O modelo atual está com desempenho aceitável, mas lento, pois as imagens têm alta dimensionalidade (28×28 pixels = 784 features).

Objetivo:

Aplicar **PCA para extrair características mais relevantes** e reduzir a dimensionalidade dos dados, mantendo o máximo possível da variância da informação original, com o intuito de acelerar o treinamento dos modelos de classificação.

Exercício

1. **Carregue o conjunto de dados MNIST.**
 2. **Visualize algumas imagens para entender o formato dos dados.**
 3. **Aplique PCA aos dados com diferentes números de componentes principais** (por exemplo: 10, 30, 50, 100).
 4. **Explique o percentual de variância explicada por cada número de componentes escolhidos.**
 5. **Treine um classificador (por exemplo, KNN ou SVM) com os dados reduzidos e compare a acurácia com o uso de todas as 784 features.**
 6. **Visualize os dados em 2D com as duas primeiras componentes principais e observe a separação entre classes.**
 7. **Discuta: Qual o melhor número de componentes? Quanta variância você perde? Qual o impacto no tempo e na acurácia?**
-

Perguntas para reflexão:

- O PCA preserva a interpretabilidade das features originais?
- É possível que a acurácia melhore mesmo com menos dimensões? Por quê?
- O PCA é um método supervisionado ou não supervisionado?