


Revisão de Literatura

Random KNN feature selection - a fast and stable alternative to Random Forests

Aluno(a): Eduardo Carvalho

Belo Horizonte, 07 de Abril de 2025



Agenda

- 1 O Problema
- 2 Seleção de Variáveis
 - Seleção Interna de Variáveis
 - Filtragem de Variáveis
 - Métodos Encapsuladores
- 3 RKNN-FS
 - *Feature Support*
 - Seleção de Variáveis
- 4 Outras Estruturas
 - V-MOSFET
 - U-MOSFET
- 5 Outras Estruturas
 - V-MOSFET
 - U-MOSFET
- 6 2/17 Referências

É comum, principalmente em problemas de bioinformática, que haja muito mais variáveis do que amostras. Isso é ruim, dado que a condição $p > n$, para p variáveis e n amostras, leva a

- alto custo computacional → mais memória ocupada; dados irrelevantes são avaliados
- overfitting → o modelo pode aprender relações que só existem naquele conjunto de dados

A seleção das variáveis é parte intrínseca do treino do modelo.

Árvore de Decisão

- Para cada variável, avalia o ganho de informação em diferentes partições
- Partições com maior ganho ficam mais próximas da raiz

Principais problemas

- Pequenas mudanças nos dados podem levar a estruturas completamente diferentes - instabilidade
- Erros são fortemente cumulativos

Floresta Aleatória

Agrega multiplas árvores de decisão, com algumas modificações

- Cada árvore é construída sobre um subconjunto dos dados
- Na construção de cada nó, um subconjunto das variáveis é considerado
- Cada árvore vota conforme seu resultado e a classificação é feita a partir destes

Principais problemas

- Mitiga, mas não resolve a instabilidade
- Aumenta o custo computacional

Analisa, estatisticamente, a relação entre cada variável e as classes do problema. Mantém aquelas que são fortes indicadores de classe.

Exemplo: Retirar variáveis cuja variância seja baixa no conjunto completo de dados, visto que estas tendem a não ser relevantes para a classificação.

Principais problemas Por não considerar a relação entre variáveis,

- pode remover aquelas que participam de relações úteis para a classificação
- pode manter variáveis redundantes

Encapsula o modelo em um problema de otimização.

- Seleciona um subconjunto das variáveis
- Treina o modelo sobre este subconjunto
- Avalia o modelo conforme uma métrica apropriada
- Seleciona o modelo com melhor performance

Principal problema: custo computacional elevado

- Para um conjunto de dados com p variáveis, r classificadores kNN são treinados em subconjuntos aleatórios de $m \approx \sqrt{p}$ variáveis
- Cada classificador é treinado sobre todas as amostras. *Bootstrapping* não é necessário, já que, por não serem hierárquicos, os classificadores são naturalmente estáveis
- A classificação é dada pelo voto majoritário entre os classificadores

- Cada variável f é atribuída a M classificadores, que formam o conjunto $C(f)$. Cada classificador recebe o conjunto $F(c)$ de variáveis
- Quando um classificador acerta sua predição, as variáveis usadas por ele recebem uma pontuação positiva
- A pontuação, por rodada, de cada variável, é a média das pontuações atribuídas por cada classificador $c \in C(f)$
- Variáveis mais relevantes para a classificação têm pontuação maior

Remoção Geométrica


- A cada iteração, a metade menos relevante das variáveis é descartada
- Após todas as iterações, a quantidade de variáveis que resulta na maior precisão é encontrada
- As variáveis presentes na iteração anterior a esta são passadas para a próxima etapa

Remoção Linear

- A cada iteração, um número fixo de variáveis é removido
- Após todas as iterações, o conjunto de variáveis mais relevantes é selecionada para o modelo

- Primeira estrutura;
- Difícil Fabricação;
- Instabilidade em uso prolongado;
- Ponta da porta prejudica a tensão de bloqueio


Figura: Estrutura V-MOSFET



Fonte: (??)

- Estrutura mais nova;
- Menor R_{on} ;
- Possibilitado por tecnologia usada em DRAM;
- Melhor desempenho em altas frequências


Figura: Estrutura U-MOSFET



Fonte: (??)

- Primeira estrutura;
- Difícil Fabricação;
- Instabilidade em uso prolongado;
- Ponta da porta prejudica a tensão de bloqueio


Figura: Estrutura V-MOSFET



Fonte: (??)

- Estrutura mais nova;
- Menor R_{on} ;
- Possibilitado por tecnologia usada em DRAM;
- Melhor desempenho em altas frequências

Figura: Estrutura U-MOSFET



Fonte: (??)

