


**Revisão de Literatura**  
***Random KNN feature selection -  
a fast and stable alternative to  
Random Forests (LI, 2011)***

**Aluno(a):** Eduardo Carvalho

Belo Horizonte, 07 de Abril de 2025



# Agenda

- 1 O Problema
- 2 Seleção de Variáveis
  - Seleção Interna de Variáveis
  - Filtragem de Variáveis
  - Métodos Encapsuladores
- 3 RKNN-FS
  - *Feature Support*
  - Seleção de Variáveis
- 4 Implementação
- 5 Resultados
  - Complexidade
  - Sugestões de parâmetros
  - Métricas
- 6 Referências

É comum, principalmente em problemas de bioinformática, que haja muito mais variáveis do que amostras. Isso é ruim, dado que a condição  $p > n$ , para  $p$  variáveis e  $n$  amostras, leva a

- alto custo computacional: mais memória ocupada; dados irrelevantes são avaliados
- overfitting: o modelo pode aprender relações que só existem naquele conjunto de dados

**Tabela:** Microarray gene expression datasets, Group II

| Dataset           | Sample Size, $n$ | No. of Genes, $p$ | No. of classes, $c$ | $p/n$ | $p \times c/n$ |
|-------------------|------------------|-------------------|---------------------|-------|----------------|
| Lymphoma          | 62               | 4026              | 3                   | 65    | 195            |
| Leukemia          | 38               | 3051              | 2                   | 80    | 161            |
| Breast.3. Classes | 95               | 4869              | 3                   | 51    | 154            |
| SRBCT             | 63               | 2308              | 4                   | 37    | 147            |
| Shipp             | 77               | 5469              | 2                   | 71    | 142            |
| Breast.2. Classes | 77               | 4869              | 2                   | 63    | 126            |
| Prostate          | 102              | 6033              | 2                   | 59    | 118            |
| Khan              | 83               | 2308              | 4                   | 28    | 111            |
| Colon             | 62               | 2000              | 2                   | 32    | 65             |


A seleção das variáveis é parte intrínseca do treino do modelo.

# Árvore de Decisão

- Para cada variável, avalia o ganho de informação em diferentes partições
- Partições com maior ganho ficam mais próximas da raiz


## Principais problemas

- Pequenas mudanças nos dados podem levar a estruturas completamente diferentes - instabilidade
- Erros são fortemente cumulativos



**Figura:** Região de decisão de uma árvore de decisão instável

Decision Tree Trained on Clean Data



Decision Tree Trained on Noisy Data




Figura: Estrutura de uma árvore de decisão instável



# Floresta Aleatória

Agrega multiplas árvores de decisão, com algumas modificações

- Cada árvore é construída sobre um subconjunto dos dados
- Na construção de cada nó, um subconjunto das variáveis é considerado
- Cada árvore vota conforme seu resultado e a classificação é feita a partir destes

## Principais problemas

- Mitiga, mas não resolve a instabilidade
- Aumenta o custo computacional




Figura: Exemplo mínimo de uma floresta aleatória

Analisa, estatisticamente, a relação entre cada variável e as classes do problema. Mantém aquelas que são fortes indicadores de classe.


**Exemplo:** Retirar variáveis cuja variância seja baixa no conjunto completo de dados, visto que estas tendem a não ser relevantes para a classificação.

**Principais problemas** Por não considerar a relação entre variáveis,


- pode remover aquelas que participam de relações úteis para a classificação
- pode manter variáveis redundantes

## Filtragem de Variáveis


XOR Dataset




Histogram for x1



Histogram for x2



Decision Boundary Based on Sign Relationship



---

```
1 Feature Definitions:
2 - X0: Informative feature (true signal)
3 - X1: Redundant copy of X0 (r = 0.996)
4 - X2: Pure noise feature (r = 0.029 with X0)
5
6 SelectKBest Results:
7 -----
8 X0: F-score = 3054.3, p-value = 4.996e-275   SELECTED
9 X1: F-score = 2914.2, p-value = 1.316e-268   SELECTED
10 X2: F-score = 0.1, p-value = 7.570e-01    REJECTED
```

---

Encapsula o modelo em um problema de otimização.

- Seleciona um subconjunto das variáveis
- Treina o modelo sobre este subconjunto
- Avalia o modelo conforme uma métrica apropriada
- Seleciona o modelo com melhor performance

**Principal problema:** custo computacional elevado

- Para um conjunto de dados com  $p$  variáveis,  $r$  classificadores  $kNN$  são treinados em subconjuntos aleatórios de  $m \approx \sqrt{p}$  variáveis
- Cada classificador é treinado sobre todas as amostras. *Bootstrapping* não é necessário, já que, por não serem hierárquicos, os classificadores são naturalmente estáveis
- A classificação é dada pelo voto majoritário entre os classificadores

- Cada variável  $f$  é atribuída a  $M$  classificadores, que formam o conjunto  $C(f)$ . Cada classificador recebe o conjunto  $F(c)$  de variáveis
- Quando um classificador acerta sua predição, as variáveis usadas por ele recebem uma pontuação positiva
- A pontuação, por rodada, de cada variável, é a média das pontuações atribuídas por cada classificador  $c \in C(f)$
- Variáveis mais relevantes para a classificação têm pontuação maior



# Remoção Geométrica

- A cada iteração, a metade menos relevante das variáveis é descartada
- Após todas as iterações, a quantidade de variáveis que resulta na maior precisão é encontrada
- As variáveis presentes na iteração anterior a esta são passadas para a próxima etapa

# Remoção Linear

- A cada iteração, um número fixo de variáveis é removido
- Após todas as iterações, o conjunto de variáveis mais relevantes é selecionada para o modelo

- $\text{support}(f) = \frac{1}{|C(f)|} \sum_{\text{kNN} \in C(f)} \text{acc}(\text{kNN})$
- $\text{number\_of\_iterations\_stg1} = \lfloor \ln(4/\text{current\_number\_of\_features}) / \ln(1 - \text{elimination\_rate}) \rfloor$
- $\text{number\_of\_iterations\_stg2} = \lfloor (\text{current\_number\_of\_features} - 4) / \text{elimination\_const} \rfloor$
- a cada iteração, computa  $\text{support}(f) \forall f$ , mantém os  $p$  melhores e atualiza  $p$

## RKNN-FS

- *feature support*:  $O(rk2^m n \log n)$
- *feature selection*:  $O(rk2^m n \log n)$
- algoritmo completo:  $O(rk2^m n \log n)$

## RF-FS

- treinamento:  $O(rmn \log n)$
- predição:  $O(r \log n)$

Para  $m = \log p$ ,  $O_{\text{rknnfs}}(rkpn \log n)$

- $k \in [1, 3]$
- $m \approx \sqrt{p}$
- $r < 1000$

Tabela: Comparative performance with gene selection, Group I

| Dataset        | $p \times c/n$ | Mean Accuracy |       |       | Standard Deviation |       |       | Coefficient of Variation |       |       |
|----------------|----------------|---------------|-------|-------|--------------------|-------|-------|--------------------------|-------|-------|
|                |                | RF            | R1NN  | R3NN  | RF                 | R1NN  | R3NN  | RF                       | R1NN  | R3NN  |
| Ramaswamy      | 1267           | 0.577         | 0.726 | 0.704 | 0.019              | 0.013 | 0.013 | 3.231                    | 1.775 | 1.796 |
| Staunton       | 859            | 0.561         | 0.692 | 0.663 | 0.042              | 0.026 | 0.031 | 7.485                    | 3.802 | 4.669 |
| Nutt           | 829            | 0.671         | 0.903 | 0.834 | 0.051              | 0.030 | 0.031 | 7.619                    | 3.268 | 3.674 |
| Su             | 792            | 0.862         | 0.901 | 0.888 | 0.016              | 0.015 | 0.014 | 1.884                    | 1.624 | 1.567 |
| NCI            | 688            | 0.813         | 0.854 | 0.836 | 0.033              | 0.027 | 0.023 | 4.083                    | 3.135 | 2.796 |
| Brain          | 666            | 0.969         | 0.958 | 0.940 | 0.025              | 0.013 | 0.018 | 2.574                    | 1.323 | 1.875 |
| Armstrong      | 468            | 0.936         | 0.993 | 0.980 | 0.020              | 0.009 | 0.013 | 2.166                    | 0.938 | 1.345 |
| Pomeroy        | 329            | 0.858         | 0.933 | 0.863 | 0.025              | 0.016 | 0.017 | 2.892                    | 1.762 | 1.991 |
| Bhattacharjee  | 310            | 0.934         | 0.956 | 0.954 | 0.015              | 0.006 | 0.006 | 1.572                    | 0.620 | 0.618 |
| Adenocarcinoma | 260            | 0.942         | 0.939 | 0.859 | 0.018              | 0.017 | 0.032 | 1.948                    | 1.808 | 3.675 |
| Golub          | 222            | 0.943         | 0.986 | 0.986 | 0.022              | 0.003 | 0.004 | 2.328                    | 0.289 | 0.369 |
| Singh          | 206            | 0.889         | 0.952 | 0.931 | 0.024              | 0.014 | 0.018 | 2.718                    | 1.427 | 1.920 |

Tabela: Comparative performance with gene selection, Group II

| Dataset   | $p \times c/n$ | Mean Accuracy |       |       | Standard Deviation |       |       | Coefficient of Variation |       |       |
|-----------|----------------|---------------|-------|-------|--------------------|-------|-------|--------------------------|-------|-------|
|           |                | RF            | R1NN  | R3NN  | RF                 | R1NN  | R3NN  | RF                       | R1NN  | R3NN  |
| Lymphoma  | 195            | 0.993         | 1.000 | 1.000 | 0.012              | 0.000 | 0.000 | 1.162                    | 0.000 | 0.000 |
| Leukemia  | 161            | 1.000         | 0.999 | 0.999 | 0.000              | 0.006 | 0.004 | 0.000                    | 0.596 | 0.427 |
| Breast.3. | 154            | 0.778         | 0.793 | 0.761 | 0.024              | 0.037 | 0.035 | 3.023                    | 4.665 | 4.639 |
| SRBCT     | 147            | 0.982         | 0.998 | 0.996 | 0.010              | 0.005 | 0.007 | 0.967                    | 0.470 | 0.684 |
| Shipp     | 142            | 0.865         | 0.997 | 0.991 | 0.033              | 0.008 | 0.011 | 3.757                    | 0.800 | 1.077 |
| Breast.2. | 126            | 0.838         | 0.841 | 0.822 | 0.024              | 0.052 | 0.042 | 2.894                    | 6.206 | 5.049 |
| Prostate  | 118            | 0.947         | 0.941 | 0.917 | 0.007              | 0.011 | 0.016 | 0.703                    | 1.154 | 1.701 |
| Khan      | 111            | 0.985         | 0.994 | 0.994 | 0.006              | 0.006 | 0.008 | 0.643                    | 0.608 | 0.809 |
| Colon     | 65             | 0.894         | 0.944 | 0.910 | 0.010              | 0.013 | 0.025 | 1.163                    | 1.337 | 2.733 |

Tabela: Average gene set size and standard deviation, Group I

| Dataset        | $p \times c/n$ | Mean Feature Set Size |      |      | Standard Deviation |      |      |
|----------------|----------------|-----------------------|------|------|--------------------|------|------|
|                |                | RF                    | R1NN | R3NN | RF                 | R1NN | R3NN |
| Ramaswamy      | 1267           | 907                   | 336  | 275  | 666                | 34   | 52   |
| Staunton       | 859            | 185                   | 74   | 60   | 112                | 12   | 11   |
| Nutt           | 829            | 146                   | 49   | 49   | 85                 | 6    | 4    |
| Su             | 792            | 858                   | 225  | 216  | 421                | 9    | 26   |
| NCI            | 688            | 126                   | 187  | 163  | 118                | 41   | 33   |
| Brain          | 666            | 18                    | 137  | 120  | 13                 | 42   | 42   |
| Armstrong      | 468            | 249                   | 76   | 73   | 1011               | 16   | 12   |
| Pomeroy        | 329            | 69                    | 89   | 82   | 70                 | 15   | 13   |
| Bhattacharjee  | 310            | 33                    | 148  | 146  | 29                 | 15   | 10   |
| Adenocarcinoma | 260            | 8                     | 38   | 11   | 4                  | 20   | 11   |
| Golub          | 222            | 12                    | 27   | 21   | 8                  | 5    | 5    |
| Singh          | 206            | 26                    | 25   | 13   | 32                 | 6    | 6    |



**Tabela:** Average gene set size and standard deviation, Group II

| Dataset   | $p \times c/n$ | Mean Feature Set Size |      |      | Standard Deviation |      |      |
|-----------|----------------|-----------------------|------|------|--------------------|------|------|
|           |                | RF                    | R1NN | R3NN | RF                 | R1NN | R3NN |
| Lymphoma  | 195            | 75                    | 114  | 103  | 30                 | 49   | 44   |
| Leukemia  | 161            | 2                     | 28   | 36   | 0                  | 22   | 18   |
| Breast.3. | 154            | 47                    | 43   | 36   | 35                 | 23   | 8    |
| SRBCT     | 147            | 49                    | 65   | 64   | 50                 | 8    | 9    |
| Shipp     | 142            | 13                    | 46   | 48   | 23                 | 9    | 6    |
| Breast.2. | 126            | 32                    | 23   | 15   | 29                 | 16   | 10   |
| Prostate  | 118            | 16                    | 32   | 15   | 10                 | 10   | 11   |
| Khan      | 111            | 17                    | 67   | 36   | 5                  | 11   | 14   |
| Colon     | 65             | 21                    | 37   | 36   | 18                 | 5    | 5    |

Tabela: Execution time comparison, Group I

| Dataset        | $p \times c/n$ | Time (min) |      |      | Ratio   |         |
|----------------|----------------|------------|------|------|---------|---------|
|                |                | RF         | R1NN | R3NN | RF/R1NN | RF/R3NN |
| Ramaswamy      | 1267           | 22335      | 4262 | 4324 | 5.2     | 5.2     |
| Staunton       | 859            | 3310       | 744  | 753  | 4.4     | 4.4     |
| Nutt           | 829            | 176        | 195  | 195  | 0.9     | 0.9     |
| Su             | 792            | 3592       | 1284 | 1279 | 2.8     | 2.8     |
| NCI            | 688            | 142        | 177  | 178  | 0.8     | 0.8     |
| Brain          | 666            | 92         | 124  | 125  | 0.7     | 0.7     |
| Armstrong      | 468            | 327        | 301  | 297  | 1.1     | 1.1     |
| Pomeroy        | 329            | 296        | 319  | 320  | 0.9     | 0.9     |
| Bhattacharjee  | 310            | 4544       | 1725 | 1733 | 2.6     | 2.6     |
| Adenocarcinoma | 260            | 274        | 272  | 273  | 1.0     | 1.0     |
| Golub          | 222            | 160        | 224  | 224  | 0.7     | 0.7     |
| Singh          | 206            | 646        | 503  | 498  | 1.3     | 1.3     |

**Tabela:** Execution time comparison, Group II

| Dataset   | $p \times c/n$ | Time (min) |      |      | Ratio   |         |
|-----------|----------------|------------|------|------|---------|---------|
|           |                | RF         | R1NN | R3NN | RF/R1NN | RF/R3NN |
| Lymphoma  | 195            | 57         | 146  | 147  | 0.4     | 0.4     |
| Leukemia  | 161            | 18         | 74   | 74   | 0.3     | 0.2     |
| Breast.3. | 154            | 310        | 332  | 334  | 0.9     | 0.9     |
| SRBCT     | 147            | 97         | 177  | 178  | 0.5     | 0.5     |
| Shipp     | 142            | 238        | 293  | 286  | 0.8     | 0.8     |
| Breast.2. | 126            | 167        | 221  | 222  | 0.8     | 0.8     |
| Prostate  | 118            | 370        | 389  | 391  | 1.0     | 0.9     |
| Khan      | 111            | 745        | 452  | 451  | 1.6     | 1.7     |
| Colon     | 65             | 75         | 156  | 157  | 0.5     | 0.5     |

 LI, e. a. Random knn feature selection - a fast and stable alternative to random forests. **BMC Bioinformatics**, v. 12, p. 450, 2011. **1**