


Revisão de Literatura
***Random KNN feature selection -
a fast and stable alternative to
Random Forests (LI, 2011)***

Aluno(a): Eduardo Carvalho

Belo Horizonte, 07 de Abril de 2025



Agenda

- 1 O Problema
- 2 Seleção de Variáveis
 - Seleção Interna de Variáveis
 - Filtragem de Variáveis
 - Métodos Encapsuladores
- 3 RKNN-FS
 - *Feature Support*
 - Seleção de Variáveis
- 4 Implementação
- 5 Resultados
 - Complexidade
 - Sugestões de parâmetros
 - Métricas
- 6 Referências

É comum, principalmente em problemas de bioinformática, que haja muito mais variáveis do que amostras. Isso é ruim, dado que a condição $p > n$, para p variáveis e n amostras, leva a

- alto custo computacional: mais memória ocupada; dados irrelevantes são avaliados
- overfitting: o modelo pode aprender relações que só existem naquele conjunto de dados

Tabela: Microarray gene expression datasets, Group II

Dataset	Sample Size, n	No. of Genes, p	No. of classes, c	p/n	$p \times c/n$
Lymphoma	62	4026	3	65	195
Leukemia	38	3051	2	80	161
Breast.3. Classes	95	4869	3	51	154
SRBCT	63	2308	4	37	147
Shipp	77	5469	2	71	142
Breast.2. Classes	77	4869	2	63	126
Prostate	102	6033	2	59	118
Khan	83	2308	4	28	111
Colon	62	2000	2	32	65

A seleção das variáveis é parte intrínseca do treino do modelo.

Árvore de Decisão

- Para cada variável, avalia o ganho de informação em diferentes partições
- Partições com maior ganho ficam mais próximas da raiz

Principais problemas

- Pequenas mudanças nos dados podem levar a estruturas completamente diferentes - instabilidade
- Erros são fortemente cumulativos





Figura: Região de decisão de uma árvore de decisão instável

Decision Tree Trained on Clean Data



Decision Tree Trained on Noisy Data




Figura: Estrutura de uma árvore de decisão instável

Floresta Aleatória

Agrega multiplas árvores de decisão, com algumas modificações

- Cada árvore é construída sobre um subconjunto dos dados
- Na construção de cada nó, um subconjunto das variáveis é considerado
- Cada árvore vota conforme seu resultado e a classificação é feita a partir destes

Principais problemas

- Mitiga, mas não resolve a instabilidade
- Aumenta o custo computacional




Figura: Exemplo mínimo de uma floresta aleatória

Analisa, estatisticamente, a relação entre cada variável e as classes do problema. Mantém aquelas que são fortes indicadores de classe.


Exemplo: Retirar variáveis cuja variância seja baixa no conjunto completo de dados, visto que estas tendem a não ser relevantes para a classificação.

Principais problemas Por não considerar a relação entre variáveis,


- pode remover aquelas que participam de relações úteis para a classificação
- pode manter variáveis redundantes

Filtragem de Variáveis


XOR Dataset




Histogram for x1



Histogram for x2



Decision Boundary Based on Sign Relationship



```
1 Feature Definitions:
2 - X0: Informative feature (true signal)
3 - X1: Redundant copy of X0 (r = 0.996)
4 - X2: Pure noise feature (r = 0.029 with X0)
5
6 SelectKBest Results:
7 -----
8 X0: F-score = 3054.3, p-value = 4.996e-275   SELECTED
9 X1: F-score = 2914.2, p-value = 1.316e-268   SELECTED
10 X2: F-score = 0.1, p-value = 7.570e-01    REJECTED
```

Encapsula o modelo em um problema de otimização.

- Seleciona um subconjunto das variáveis
- Treina o modelo sobre este subconjunto
- Avalia o modelo conforme uma métrica apropriada
- Seleciona o modelo com melhor performance

Principal problema: custo computacional elevado

- Para um conjunto de dados com p variáveis, r classificadores kNN são treinados em subconjuntos aleatórios de $m \approx \sqrt{p}$ variáveis
- Cada classificador é treinado sobre todas as amostras. *Bootstrapping* não é necessário, já que, por não serem hierárquicos, os classificadores são naturalmente estáveis
- A classificação é dada pelo voto majoritário entre os classificadores

- Cada variável f é atribuída a M classificadores, que formam o conjunto $C(f)$. Cada classificador recebe o conjunto $F(c)$ de variáveis
- Quando um classificador acerta sua predição, as variáveis usadas por ele recebem uma pontuação positiva
- A pontuação, por rodada, de cada variável, é a média das pontuações atribuídas por cada classificador $c \in C(f)$
- Variáveis mais relevantes para a classificação têm pontuação maior

Remoção Geométrica

- A cada iteração, a metade menos relevante das variáveis é descartada
- Após todas as iterações, a quantidade de variáveis que resulta na maior precisão é encontrada
- As variáveis presentes na iteração anterior a esta são passadas para a próxima etapa

Remoção Linear

- A cada iteração, um número fixo de variáveis é removido
- Após todas as iterações, o conjunto de variáveis mais relevantes é selecionada para o modelo

- $\text{support}(f) = \frac{1}{|C(f)|} \sum_{\text{kNN} \in C(f)} \text{acc}(\text{kNN})$
- $\text{number_of_iterations_stg1} = \lfloor \ln(4/\text{current_number_of_features}) / \ln(1 - \text{elimination_rate}) \rfloor$
- $\text{number_of_iterations_stg2} = \lfloor (\text{current_number_of_features} - 4) / \text{elimination_const} \rfloor$
- a cada iteração, computa $\text{support}(f) \forall f$, mantém os p melhores e atualiza p

$$O(rk2^{\sqrt{p}}n \log n)$$

- $k \in [1, 3]$
- $m \approx \sqrt{p}$
- $r < 1000$

Tabela: Comparative performance with gene selection, Group I

Dataset	$p \times c/n$	Mean Accuracy			Standard Deviation			Coefficient of Variation		
		RF	R1NN	R3NN	RF	R1NN	R3NN	RF	R1NN	R3NN
Ramaswamy	1267	0.577	0.726	0.704	0.019	0.013	0.013	3.231	1.775	1.796
Staunton	859	0.561	0.692	0.663	0.042	0.026	0.031	7.485	3.802	4.669
Nutt	829	0.671	0.903	0.834	0.051	0.030	0.031	7.619	3.268	3.674
Su	792	0.862	0.901	0.888	0.016	0.015	0.014	1.884	1.624	1.567
NCI	688	0.813	0.854	0.836	0.033	0.027	0.023	4.083	3.135	2.796
Brain	666	0.969	0.958	0.940	0.025	0.013	0.018	2.574	1.323	1.875
Armstrong	468	0.936	0.993	0.980	0.020	0.009	0.013	2.166	0.938	1.345
Pomeroy	329	0.858	0.933	0.863	0.025	0.016	0.017	2.892	1.762	1.991
Bhattacharjee	310	0.934	0.956	0.954	0.015	0.006	0.006	1.572	0.620	0.618
Adenocarcinoma	260	0.942	0.939	0.859	0.018	0.017	0.032	1.948	1.808	3.675
Golub	222	0.943	0.986	0.986	0.022	0.003	0.004	2.328	0.289	0.369
Singh	206	0.889	0.952	0.931	0.024	0.014	0.018	2.718	1.427	1.920

Tabela: Comparative performance with gene selection, Group II

Dataset	$p \times c/n$	Mean Accuracy			Standard Deviation			Coefficient of Variation		
		RF	R1NN	R3NN	RF	R1NN	R3NN	RF	R1NN	R3NN
Lymphoma	195	0.993	1.000	1.000	0.012	0.000	0.000	1.162	0.000	0.000
Leukemia	161	1.000	0.999	0.999	0.000	0.006	0.004	0.000	0.596	0.427
Breast.3.	154	0.778	0.793	0.761	0.024	0.037	0.035	3.023	4.665	4.639
SRBCT	147	0.982	0.998	0.996	0.010	0.005	0.007	0.967	0.470	0.684
Shipp	142	0.865	0.997	0.991	0.033	0.008	0.011	3.757	0.800	1.077
Breast.2.	126	0.838	0.841	0.822	0.024	0.052	0.042	2.894	6.206	5.049
Prostate	118	0.947	0.941	0.917	0.007	0.011	0.016	0.703	1.154	1.701
Khan	111	0.985	0.994	0.994	0.006	0.006	0.008	0.643	0.608	0.809
Colon	65	0.894	0.944	0.910	0.010	0.013	0.025	1.163	1.337	2.733

Tabela: Average gene set size and standard deviation, Group I

Dataset	$p \times c/n$	Mean Feature Set Size			Standard Deviation		
		RF	R1NN	R3NN	RF	R1NN	R3NN
Ramaswamy	1267	907	336	275	666	34	52
Staunton	859	185	74	60	112	12	11
Nutt	829	146	49	49	85	6	4
Su	792	858	225	216	421	9	26
NCI	688	126	187	163	118	41	33
Brain	666	18	137	120	13	42	42
Armstrong	468	249	76	73	1011	16	12
Pomeroy	329	69	89	82	70	15	13
Bhattacharjee	310	33	148	146	29	15	10
Adenocarcinoma	260	8	38	11	4	20	11
Golub	222	12	27	21	8	5	5
Singh	206	26	25	13	32	6	6

Tabela: Average gene set size and standard deviation, Group II

Dataset	$p \times c/n$	Mean Feature Set Size			Standard Deviation		
		RF	R1NN	R3NN	RF	R1NN	R3NN
Lymphoma	195	75	114	103	30	49	44
Leukemia	161	2	28	36	0	22	18
Breast.3.	154	47	43	36	35	23	8
SRBCT	147	49	65	64	50	8	9
Shipp	142	13	46	48	23	9	6
Breast.2.	126	32	23	15	29	16	10
Prostate	118	16	32	15	10	10	11
Khan	111	17	67	36	5	11	14
Colon	65	21	37	36	18	5	5

Tabela: Execution time comparison, Group I

Dataset	$p \times c/n$	Time (min)			Ratio	
		RF	R1NN	R3NN	RF/R1NN	RF/R3NN
Ramaswamy	1267	22335	4262	4324	5.2	5.2
Staunton	859	3310	744	753	4.4	4.4
Nutt	829	176	195	195	0.9	0.9
Su	792	3592	1284	1279	2.8	2.8
NCI	688	142	177	178	0.8	0.8
Brain	666	92	124	125	0.7	0.7
Armstrong	468	327	301	297	1.1	1.1
Pomeroy	329	296	319	320	0.9	0.9
Bhattacharjee	310	4544	1725	1733	2.6	2.6
Adenocarcinoma	260	274	272	273	1.0	1.0
Golub	222	160	224	224	0.7	0.7
Singh	206	646	503	498	1.3	1.3

Tabela: Execution time comparison, Group II

Dataset	$p \times c/n$	Time (min)			Ratio	
		RF	R1NN	R3NN	RF/R1NN	RF/R3NN
Lymphoma	195	57	146	147	0.4	0.4
Leukemia	161	18	74	74	0.3	0.2
Breast.3.	154	310	332	334	0.9	0.9
SRBCT	147	97	177	178	0.5	0.5
Shipp	142	238	293	286	0.8	0.8
Breast.2.	126	167	221	222	0.8	0.8
Prostate	118	370	389	391	1.0	0.9
Khan	111	745	452	451	1.6	1.7
Colon	65	75	156	157	0.5	0.5

 LI, e. a. Random knn feature selection - a fast and stable alternative to random forests. **BMC Bioinformatics**, v. 12, p. 450, 2011. **1**